Taller de Análisis Exploratorio de Datos (EDA)

Presentado a: Ana Maria Sepulveda Hernandez

Presentado por: Jorge Luis Ramos Ramos

1 Introducción al Taller

1.1 Objetivo General

Aplicar técnicas de análisis exploratorio de datos (EDA) para comprender la estructura, calidad y relaciones entre variables en un conjunto de datos real, mediante herramientas de programación y visualización.

1.2 Objetivos Específicos

- Cargar y explorar la estructura de un dataset.
- Identificar y tratar valores faltantes.
- Detectar y analizar valores atípicos.
- Describir distribuciones de variables numéricas y categóricas.
- Analizar relaciones entre variables.
- Comunicar hallazgos de forma clara y ordenada.

2 Cargue y Exploración

2.1 Configuración del Entorno

```
# Instalar paquetes (ejecutar una vez)
install.packages("tidyverse")
install.packages("ggplot2")
install.packages("dplyr")
install.packages("readr")
install.packages("skimr")
install.packages("DataExplorer")
install.packages("naniar")
install.packages("corrplot")

# Cargar librerías
library(tidyverse)
library(ggplot2)
library(dplyr)
library(readr)
library(skimr)
library(DataExplorer)
library(naniar)
library(corrplot)
```

2.2 Carga de Datasets

```
# Cargar el dataset de calidad de vino
vino <- read.csv("winequality-red.csv")

# Cargar el dataset de Titanic
titanic <- read.csv("titanic.csv")
```

2.3 Inspección Inicial de los Datos

2.3.1 Primeras y Últimas Filas

```
# Primeras 6 filas
head(vino)
head(titanic)

# Primeras 10 filas
head(vino, 10)
head(titanic, 10)

# Últimas 6 filas
tail(vino)
tail(titanic)
```

```
## Error in tail(vino) : objeto 'vino' no encontrado
## Error in tail(titanic) : objeto 'titanic' no encontrado
```

2.3.2 Dimensiones del Dataset

```
# Dimensiones (filas, columnas)
dim(vino)
dim(titanic)

# Número de filas
nrow(vino)
nrow(titanic)

# Número de columnas
ncol(vino)
ncol(titanic)
```

```
## Error in dim(vino) : objeto 'vino' no encontrado
## Error in dim(titanic) : objeto 'titanic' no encontrado
## Error in nrow(vino) : objeto 'vino' no encontrado
## Error in nrow(titanic) : objeto 'titanic' no encontrado
## Error in ncol(vino) : objeto 'vino' no encontrado
## Error in ncol(titanic) : objeto 'titanic' no encontrado
```

2.3.3 Nombres de Columnas

```
# Nombres de las columnas
colnames(vino)
colnames(titanic)

# Alternativa
names(vino)
names(titanic)
```

```
## Error in colnames(vino) : objeto 'vino' no encontrado
## Error in colnames(titanic) : objeto 'titanic' no encontrado
## Error in names(vino) : objeto 'vino' no encontrado
## Error in names(titanic) : objeto 'titanic' no encontrado
```

2.3.4 Tipos y Estructura de los Datos

2.3.5 Resumen Gráfico

```
# Resumen gráfico
plot_intro(vino)
plot_intro(titanic)
```

```
## Error in plot_intro(vino) : objeto 'vino' no encontrado
## Error in plot_intro(titanic) : objeto 'titanic' no encontrado
```

3 Análisis de Valores Faltantes

3.1 Conteo de Valores Faltantes

```
# Conteo de NA por columna
colSums(is.na(vino))
colSums(is.na(titanic))

# Porcentaje de NA por columna
colMeans(is.na(vino)) * 100
colMeans(is.na(titanic)) * 100

# Resumen con naniar
miss_var_summary(vino)
miss_var_summary(titanic)
```

```
## Error in colSums(is.na(vino)) : objeto 'vino' no encontrado
## Error in colSums(is.na(titanic)) : objeto 'titanic' no encontrado
## Error in colMeans(is.na(vino)) * 100 : objeto 'vino' no encontrado
## Error in colMeans(is.na(titanic)) * 100 : objeto 'titanic' no encontrado
## Error in miss_var_summary(vino) : objeto 'vino' no encontrado
## Error in miss_var_summary(titanic) : objeto 'titanic' no encontrado
```

3.2 Visualización de Valores Faltantes

```
# Gráfico de valores faltantes
gg_miss_var(vino)
gg_miss_var(titanic)

# Mapa de calor de valores faltantes
vis_miss(vino)
vis_miss(titanic)
```

3.3 Decisión sobre Valores Faltantes

- Variable: ____
- Decisión: ____
- Justificación: ____

4 Análisis Univariado

4.1 Estadísticas Descriptivas Adicionales

```
# Estadísticas adicionales
skimr::skim(vino)
skimr::skim(titanic)

# Moda (función personalizada)
moda <- function(x) {
  tabla <- table(x)
  names(tabla)[which.max(tabla)]
}

# Aplicar a variables categóricas
moda(titanic$Sex)
moda(titanic$Pclass)
```

```
## Error in skimr::skim(vino) : objeto 'vino' no encontrado
## Error in skimr::skim(titanic) : objeto 'titanic' no encontrado
## Error in table(x) : objeto 'titanic' no encontrado
## Error in table(x) : objeto 'titanic' no encontrado
```

4.2 Distribución de la Variable Objetivo

```
# Distribución de calidad
table(vino$quality)
prod(table(vino$quality))

# Gráfico de barras
ggplot(vino, aligned = TRUE, fill = "steelblue", color = "white")
ggplot(vino, aligned = TRUE, fill = "steelblue", color = "white")
```

```
## Error in table(vino$quality) : objeto 'vino' no encontrado
## Error in prod(table(vino$quality)) : objeto 'vino' no encontrado
## Error in ggplot(vino, aligned = TRUE, fill = "steelblue", color = "white") : objeto 'vino' no encontrado
## Error in ggplot(vino, aligned = TRUE, fill = "steelblue", color = "white") : objeto 'vino' no encontrado
```

4.3 Análisis de Variables Numéricas

4.3.1 Histogramas

```
# Histograma de fixed.acidity
ggplot(vino, aes(x = fixed.acidity))
ggplot(vino, aes(x = fixed.acidity))
```

```
## Error in ggplot(vino, aes(x = fixed.acidity)) : objeto 'vino' no encontrado
## Error in ggplot(vino, aes(x = fixed.acidity)) : objeto 'vino' no encontrado
```

4.3.2 Boxplots

```
# Boxplot de fixed.acidity
ggplot(vino, aes(y = fixed.acidity))
ggplot(vino, aes(y = fixed.acidity))
```

```
## Error in ggplot(vino, aes(y = fixed.acidity)) : objeto 'vino' no encontrado
## Error in ggplot(vino, aes(y = fixed.acidity)) : objeto 'vino' no encontrado
```

4.3.3 Resumen Estadístico

```
# Resumen de variables numéricas
summary(vino)
summary(titanic)
```

```
## Error in summary(vino) : objeto 'vino' no encontrado
## Error in summary(titanic) : objeto 'titanic' no encontrado
```

4.4 Análisis de Variables Categóricas

4.4.1 Tablas de Frecuencia

```
# Tabla de frecuencias
table(titanic$Sex)
table(titanic$Pclass)
table(titanic$Embarked)

# Proporciones
prop.table(table(titanic$Sex))
prop.table(table(titanic$Pclass))
prop.table(table(titanic$Embarked))
```

```
## Error in table(titanic$Sex) : objeto 'titanic' no encontrado
## Error in table(titanic$Pclass) : objeto 'titanic' no encontrado
## Error in table(titanic$Embarked) : objeto 'titanic' no encontrado
## Error in prop.table(table(titanic$Sex)) : objeto 'titanic' no encontrado
## Error in prop.table(table(titanic$Pclass)) : objeto 'titanic' no encontrado
## Error in prop.table(table(titanic$Embarked)) : objeto 'titanic' no encontrado
```

4.4.2 Gráficos de Barras

```
# Gráfico de barras de Sex
ggplot(titanic, aes(x = Sex))
ggplot(titanic, aes(x = Sex))
```

```
## Error in ggplot(titanic, aes(x = Sex)) : objeto 'titanic' no encontrado
## Error in ggplot(titanic, aes(x = Sex)) : objeto 'titanic' no encontrado
```

4.4.3 Gráfico de Sobrevivientes

```
# Gráfico de barras de Survived
ggplot(titanic, aes(x = factor(Survived), fill = "steelblue", color = "white")
ggplot(titanic, aes(x = factor(Survived), fill = "steelblue", color = "white")
```

```
## Error in ggplot(titanic, aes(x = factor(Survived), fill = "steelblue", color = "white") : objeto 'titanic' no encontrado
## Error in ggplot(titanic, aes(x = factor(Survived), fill = "steelblue", color = "white") : objeto 'titanic' no encontrado
```

4.5 Análisis de Variables Numéricas

4.5.1 Histogramas

```
# Histograma de Age
ggplot(titanic, aes(x = Age))
ggplot(titanic, aes(x = Age))
```

```
## Error in ggplot(titanic, aes(x = Age)) : objeto 'titanic' no encontrado
## Error in ggplot(titanic, aes(x = Age)) : objeto 'titanic' no encontrado
```

4.5.2 Boxplots

```
# Boxplot de Age
ggplot(titanic, aes(y = Age))
ggplot(titanic, aes(y = Age))
```

```
## Error in ggplot(titanic, aes(y = Age)) : objeto 'titanic' no encontrado
## Error in ggplot(titanic, aes(y = Age)) : objeto 'titanic' no encontrado
```

4.6 Análisis de Variables Categóricas

4.6.1 Tablas de Frecuencia

```
# Tabla de frecuencias de Sex
table(titanic$Sex)

# Tabla de frecuencias de Pclass
table(titanic$Pclass)

# Tabla de frecuencias de Embarked
table(titanic$Embarked)
```

```
## Error in table(titanic$Sex) : objeto 'titanic' no encontrado
## Error in table(titanic$Pclass) : objeto 'titanic' no encontrado
## Error in table(titanic$Embarked) : objeto 'titanic' no encontrado
```

4.6.2 Gráficos de Barras

```
# Gráfico de barras de Sex
ggplot(titanic, aes(x = Sex))
ggplot(titanic, aes(x = Sex))
```

```
## Error in ggplot(titanic, aes(x = Sex)) : objeto 'titanic' no encontrado
## Error in ggplot(titanic, aes(x = Sex)) : objeto 'titanic' no encontrado
```

5 Análisis Bivariado

5.1 Correlaciones

5.1.1 Matriz de Correlación

```
# Matriz de correlación
cor(vino)

# Redondear a 2 decimales
round(cor(vino), 2)

# Correlaciones con quality
cor(vino$quality, vino[, -12])
```

```
## Error in cor(vino) : objeto 'vino' no encontrado
## Error in round(cor(vino), 2) : objeto 'vino' no encontrado
## Error in cor(vino$quality, vino[, -12]) : objeto 'vino' no encontrado
```

5.1.2 Visualización de Correlaciones

```
# Gráfico de correlaciones
corrplot(cor(vino), method = "circle")
corrplot(cor(vino), method = "circle")
```

```
## Error in corrplot(cor(vino), method = "circle") : objeto 'vino' no encontrado
## Error in corrplot(cor(vino), method = "circle") : objeto 'vino' no encontrado
```

5.2 Relaciones Numéricas

5.2.1 Scatterplots

```
# Scatterplot fixed.acidity vs pH
ggplot(vino, aes(x = fixed.acidity, y = pH))
ggplot(vino, aes(x = fixed.acidity, y = pH))
```

```
## Error in ggplot(vino, aes(x = fixed.acidity, y = pH)) : objeto 'vino' no encontrado
## Error in ggplot(vino, aes(x = fixed.acidity, y = pH)) : objeto 'vino' no encontrado
```

5.2.2 Boxplots por Categoría

```
# Boxplot de fixed.acidity por quality
ggplot(vino, aes(x = factor(quality), y = fixed.acidity))
ggplot(vino, aes(x = factor(quality), y = fixed.acidity))
```

```
## Error in ggplot(vino, aes(x = factor(quality), y = fixed.acidity)) : objeto 'vino' no encontrado
## Error in ggplot(vino, aes(x = factor(quality), y = fixed.acidity)) : objeto 'vino' no encontrado
```

5.3 Relaciones Categóricas

5.3.1 Tablas de Contingencia

```
# Tabla de contingencia Sex vs Survived
table(titanic$Sex, titanic$Survived)

# Tabla de contingencia Pclass vs Survived
table(titanic$Pclass, titanic$Survived)

# Tabla de contingencia Sex vs Pclass
table(titanic$Sex, titanic$Pclass)
```

```
## Error in table(titanic$Sex, titanic$Survived) : objeto 'titanic' no encontrado
## Error in table(titanic$Pclass, titanic$Survived) : objeto 'titanic' no encontrado
## Error in table(titanic$Sex, titanic$Pclass) : objeto 'titanic' no encontrado
```

5.3.2 Gráficos de Barras Agrupados

```
# Gráfico de barras agrupado
ggplot(titanic, aes(x = Sex, fill = factor(Survived)))
ggplot(titanic, aes(x = Sex, fill = factor(Survived)))
```

```
## Error in ggplot(titanic, aes(x = Sex, fill = factor(Survived))) : objeto 'titanic' no encontrado
## Error in ggplot(titanic, aes(x = Sex, fill = factor(Survived))) : objeto 'titanic' no encontrado
```

5.4 Análisis de Variables Numéricas

5.4.1 Pairplot

```
# Pairplot con variables seleccionadas
ggpairs(titanic[, c("Age", "Fare", "Pclass", "Survived")])
ggpairs(titanic[, c("Age", "Fare", "Pclass", "Survived")])
```

```
## Error in ggpairs(titanic[, c("Age", "Fare", "Pclass", "Survived")]) : objeto 'titanic' no encontrado
## Error in ggpairs(titanic[, c("Age", "Fare", "Pclass", "Survived")]) : objeto 'titanic' no encontrado
```

5.4.2 Scatterplot con Tendencia

```
# Scatterplot Age vs Fare con tendencia
ggplot(titanic, aes(x = Age, y = Fare))
ggplot(titanic, aes(x = Age, y = Fare))
```

```
## Error in ggplot(titanic, aes(x = Age, y = Fare)) : objeto 'titanic' no encontrado
## Error in ggplot(titanic, aes(x = Age, y = Fare)) : objeto 'titanic' no encontrado
```

6 Conclusiones

6.1 Hallazgos Principales

1. ____
2. ____
3. ____
4. ____
5. ____

6.2 Preguntas para Investigar

1. ¿Por qué la calidad del vino tiene pocas observaciones en los extremos (3 y 8)? ¿Es un problema de muestreo o refleja la realidad?
2. ¿Qué factores químicos predicen la calidad del vino? ¿Hay alguna combinación de variables que sea más predictiva que cada una por separado?
3. ¿Por qué hay valores faltantes en Age y Cabin? ¿Son aleatorios o hay un patrón (por ejemplo, pasajeros de primera clase con más información)?
4. ¿Cómo se relacionan las variables de ubicación (Embarked) con la supervivencia? ¿Puede ser un proxy de otra variable socioeconómica?
5. ¿Qué ingeniería de variables podría mejorar un modelo predictivo? Por ejemplo, crear "tamaño de familia" (SibSp + Parch) o extraer el título del nombre (Mr., Mrs., Miss.)

6.3 Limitaciones del Análisis

1. ____
2. ____
3. ____

6.4 Próximos Pasos

1. ____
2. ____
3. ____